



UNIVERSIDADE FEDERAL DO PIAUÍ
UFPI – CCN – DC
CIÊNCIA DA COMPUTAÇÃO
TÓPICOS ESPECIAL EM COMPUTAÇÃO:
COMPUTAÇÃO SOCIAL E URBANA
PROF. DR. GLAUBER DIAS GONÇALVES



Atividade 04

Agrupamento em grafos

Abril, 2025



Equipe



Enzo Borges Rocha Lima

Membro



Luis Felipe do Nascimento Moura

Membro



Objetivo



-
- Aplicar os algoritmos de detecção de comunidades:
 - Edge Betweenness
 - Louvain
 - Leiden
 - Avaliar os resultados com modularidade.
 - Comparar e discutir o melhor agrupamento.



Algoritmos

Edge Betweenness

- Remove arestas com maior centralidade de intermediação.
- Comunidades são formadas quando o grafo se desconecta.

Louvain (multilevel)

- Baseado em maximização de modularidade
- Rápido e eficaz para grandes redes
- Não garante comunidades conectadas

Leiden

- Melhoria sobre Louvain
- Garante comunidades conectadas

Algoritmos

Artigo de referência

- Uso do modelo LFR
 - É uma abordagem para gerar redes complexas que simula a estrutura de comunidades em grafos.
 - Gera redes não direcionadas e não ponderadas com comunidades não sobrepostas.
 - Amplamente utilizado como um benchmark para testar e comparar algoritmos de detecção de comunidades.
- A precisão é medida pela similaridade entre a estrutura modular gerada pelo modelo LFR e a partição identificada pelos algoritmos.
- Padrão de Mistura
 - O padrão de mistura refere-se à forma como os nós em uma rede estão conectados entre si, especialmente em relação à formação de comunidades.
- Parâmetro de Mistura (μ):
 - O parâmetro de mistura (μ) quantifica a proporção de conexões dentro de comunidades em comparação com conexões entre diferentes comunidades.
 - Valores baixos de μ indicam que a maioria das conexões está dentro das comunidades, enquanto valores altos indicam uma mistura maior entre as comunidades.
- A maioria dos algoritmos apresenta boa precisão quando o parâmetro de mistura (μ) é baixo ($\mu \leq 0.2$), mas a precisão diminui à medida que μ aumenta.
- O tempo de computação varia entre os algoritmos, com o **Multilevel** e o Label Propagation sendo os mais rápidos, enquanto Spinglass e Edge Betweenness são os mais lentos.
- O estudo avalia **oito algoritmos** de detecção de comunidades usando o benchmark LFR.
 - Infomap; Label Propagation; **Multilevel**; Walktrap; Spinglass; Edge Betweenness; Leading Eigenvector; Fastgreedy

Algoritmos

- **NetworkX**

- Funciona super bem com pandas, matplotlib, numpy, etc.
- Sintaxe intuitiva, mais próxima de um dicionário de listas.
- Muito mais lento que iGraph em operações como centralidade, shortest path, clustering.
- Estrutura interna usa dicionários aninhados, que consomem muita RAM.

- **iGraph**


- Muito mais rápido e leve para grafos com milhares/milhões de nós.
- Baixo consumo de memória
- Integração com pandas/numpy fraca
- Precisa adaptar os dados, pois não usa dicionários nativos.

Clube do karatê

Original

Nº de vértices: 33

Nº de arestas: 78




Clube do karatê

Edge Betweenness

- Arestas centrais:

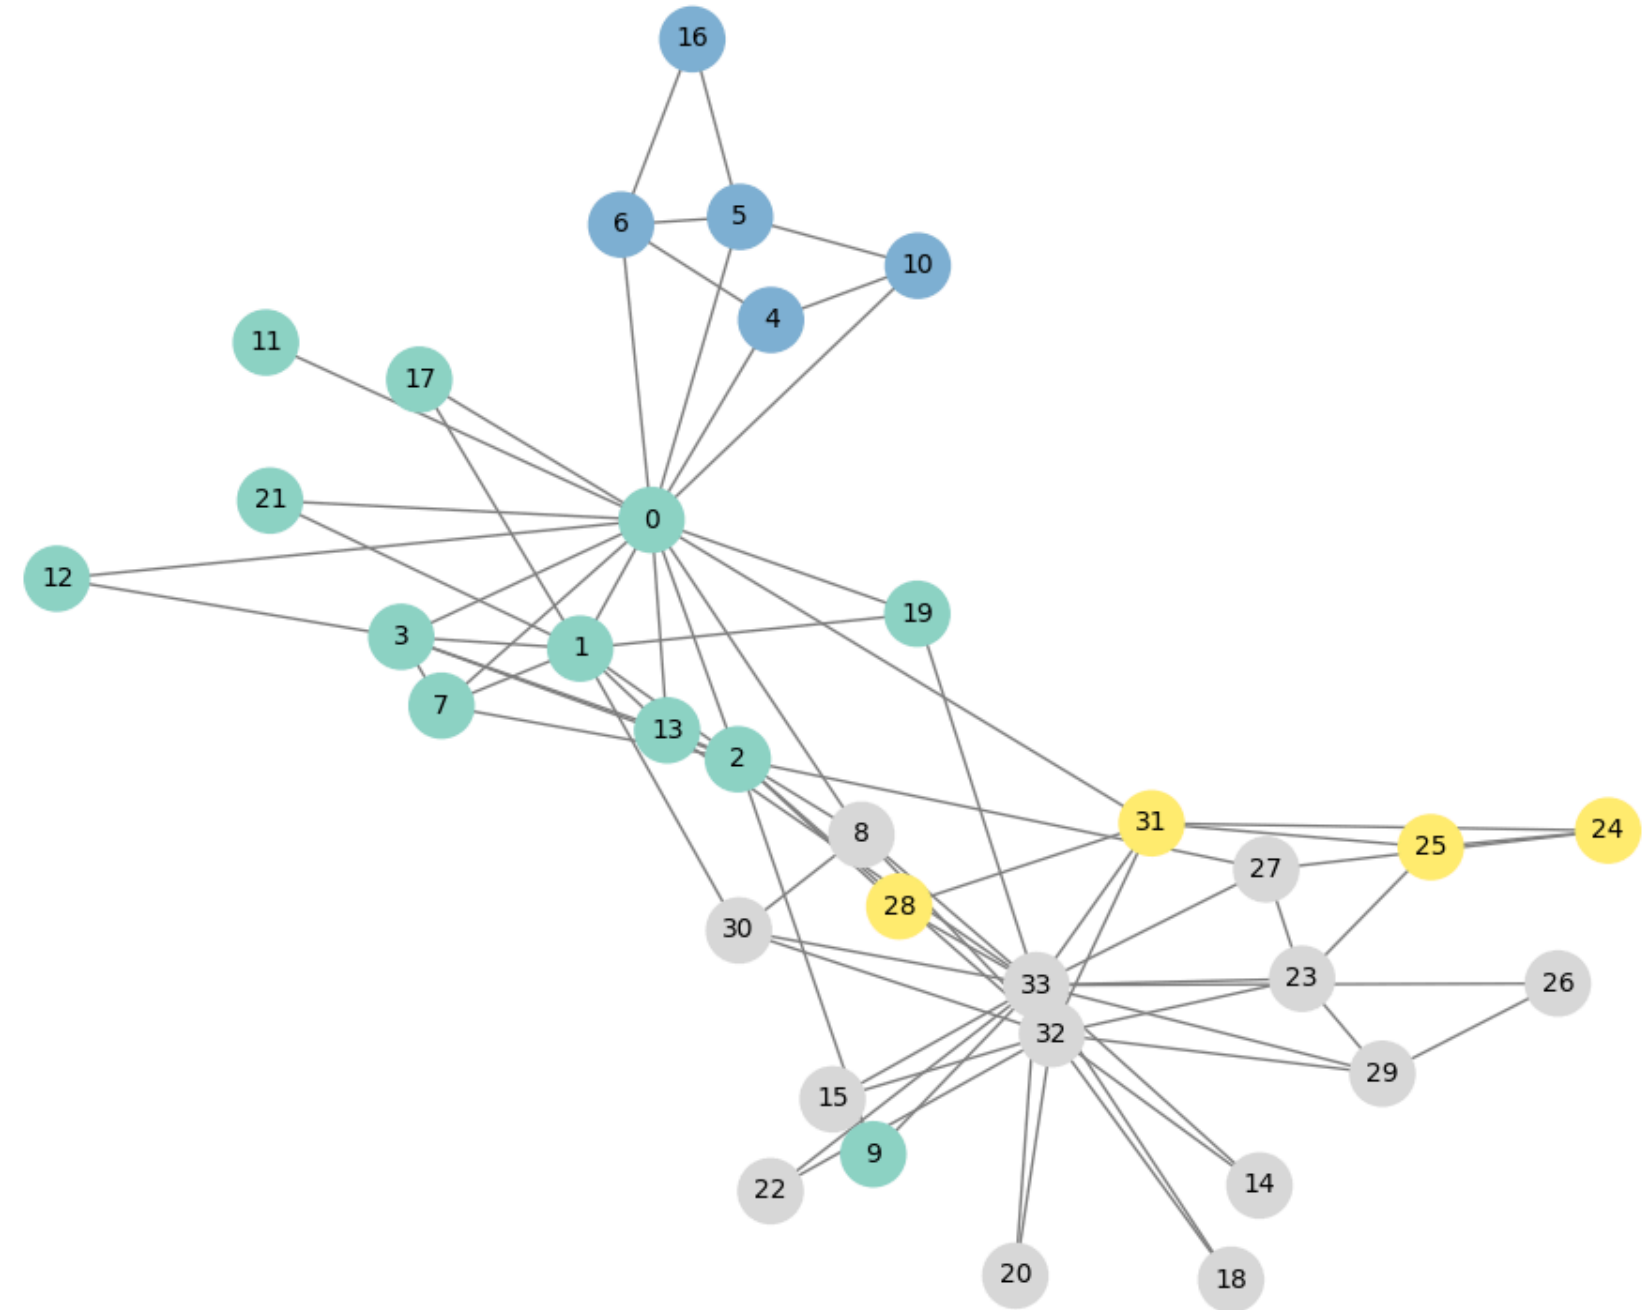
- (0, 31): 0,1273
- (0, 6) : 0,0781
- (0, 5) : 0,0781
- (0, 2) : 0,0778
- (0, 8) : 0,0742



Clube do karatê

Louvain


- Número de comunidades: 4



Clube do karatê

Leiden

- Número de comunidades: 4

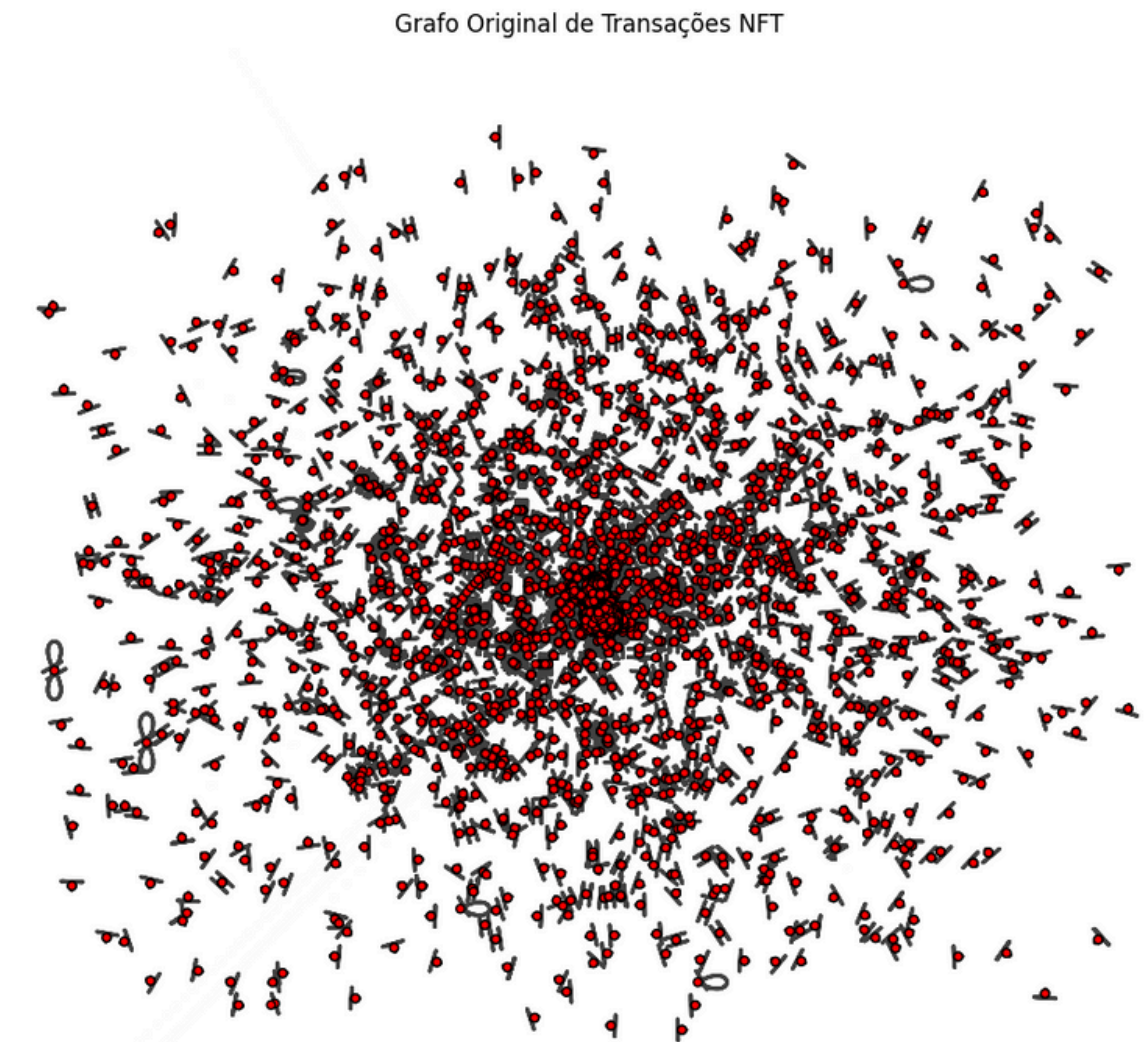


Transações de NFT

Original

Nº de vértices: 83.889

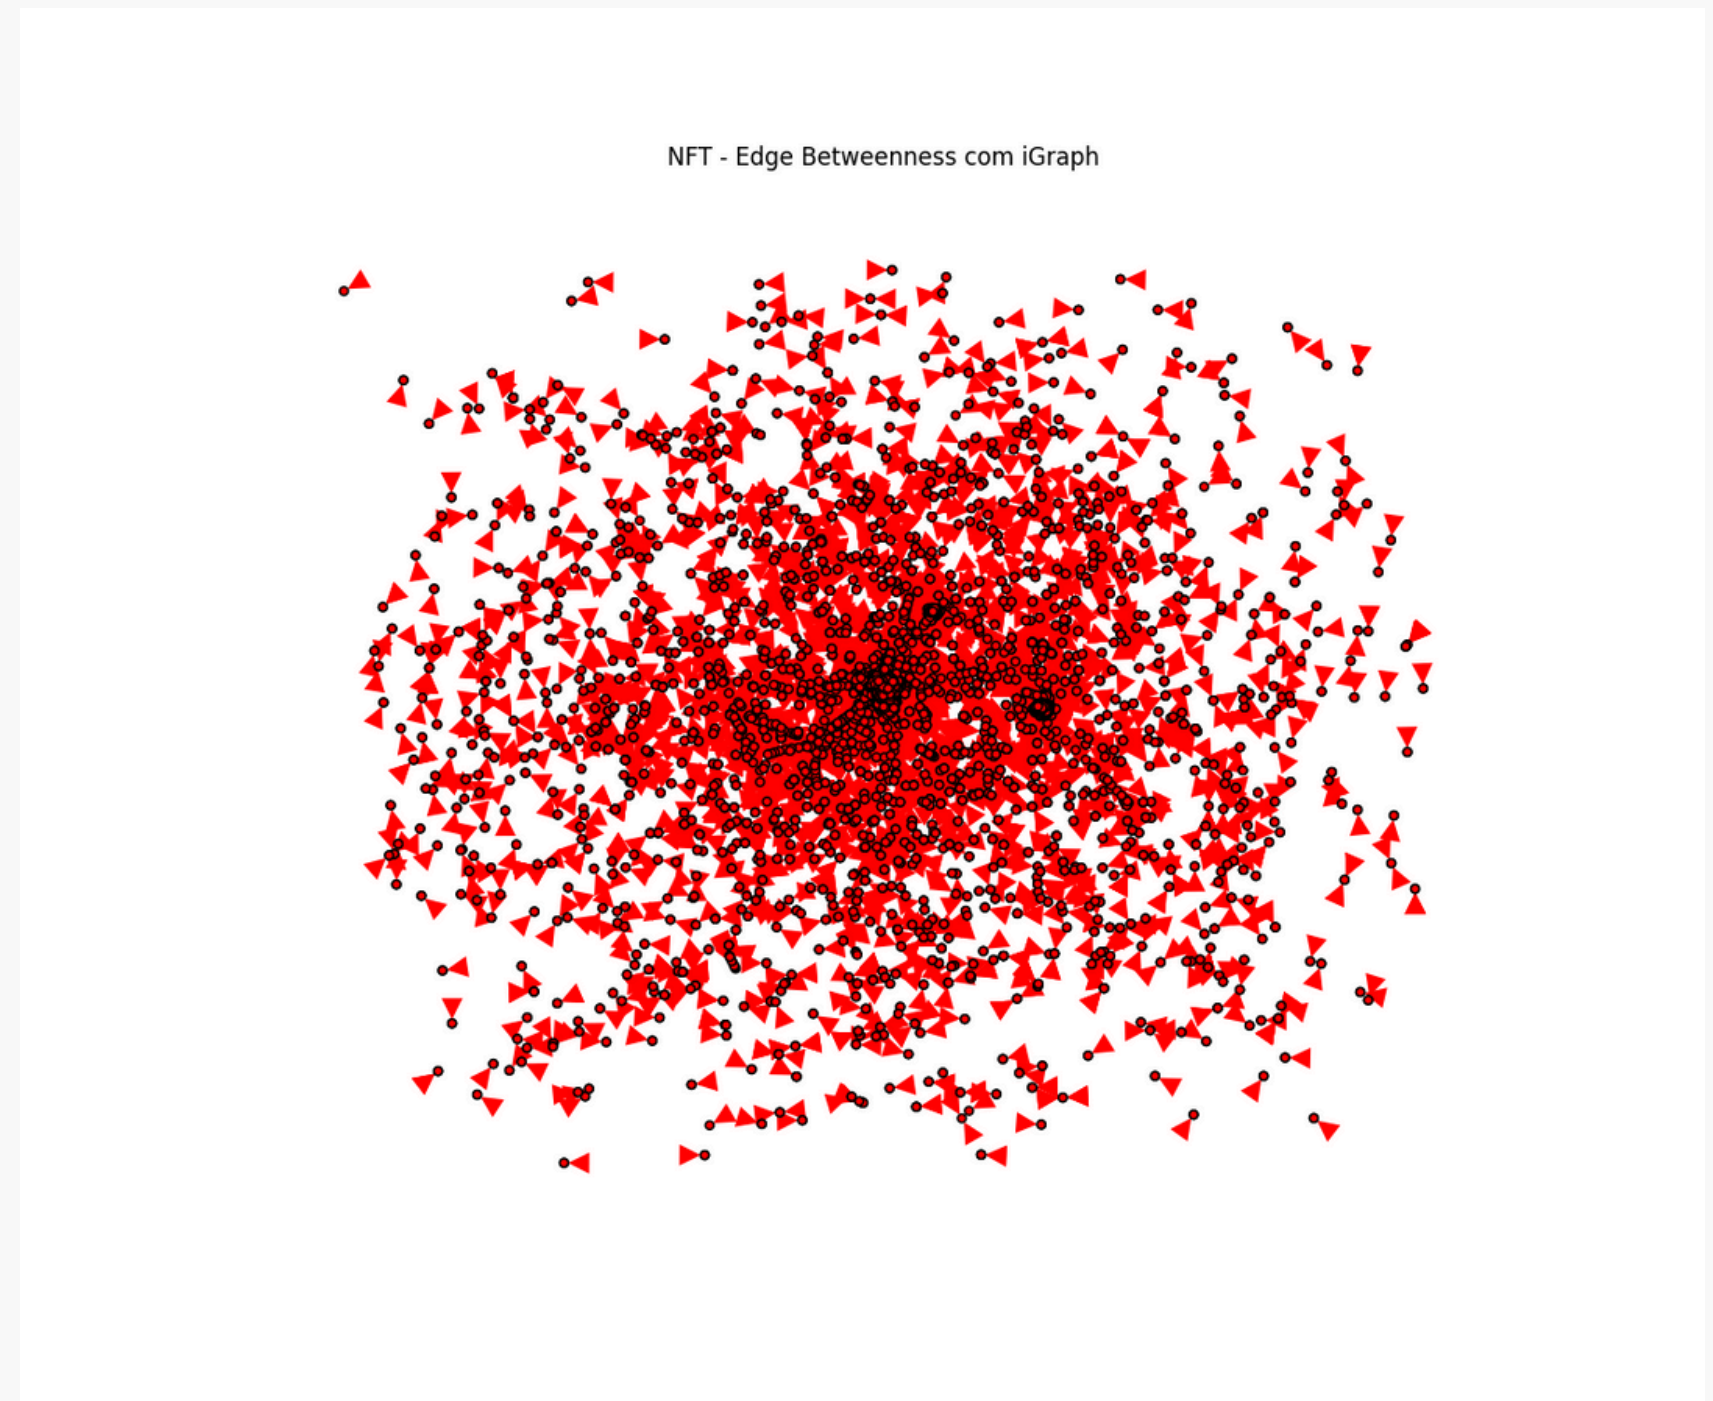
Nº de arestas: 1.245.954



Transações de NFT

Edge Betweenness

- Arestas centrais:
 - (60077, 27902) : 48.457.950,5692
 - (57151, 71067) : 29.201.312,4618
 - (45178, 60077) : 28.331.305,3150
 - (46368, 4124) : 13.194.288,3803
 - (46368, 4124) : 13.194.288,3803




Transações de NFT

Edge Betweenness (zoom)

- Arestas centrais:


- (0, 31): 0,1273
- (0, 6) : 0,0781
- (0, 5) : 0,0781
- (0, 2) : 0,0778
- (0, 8) : 0,0742



Transações de NFT

Louvain


- Número de comunidades: 1601



Transações de NFT

Louvain (zoom)

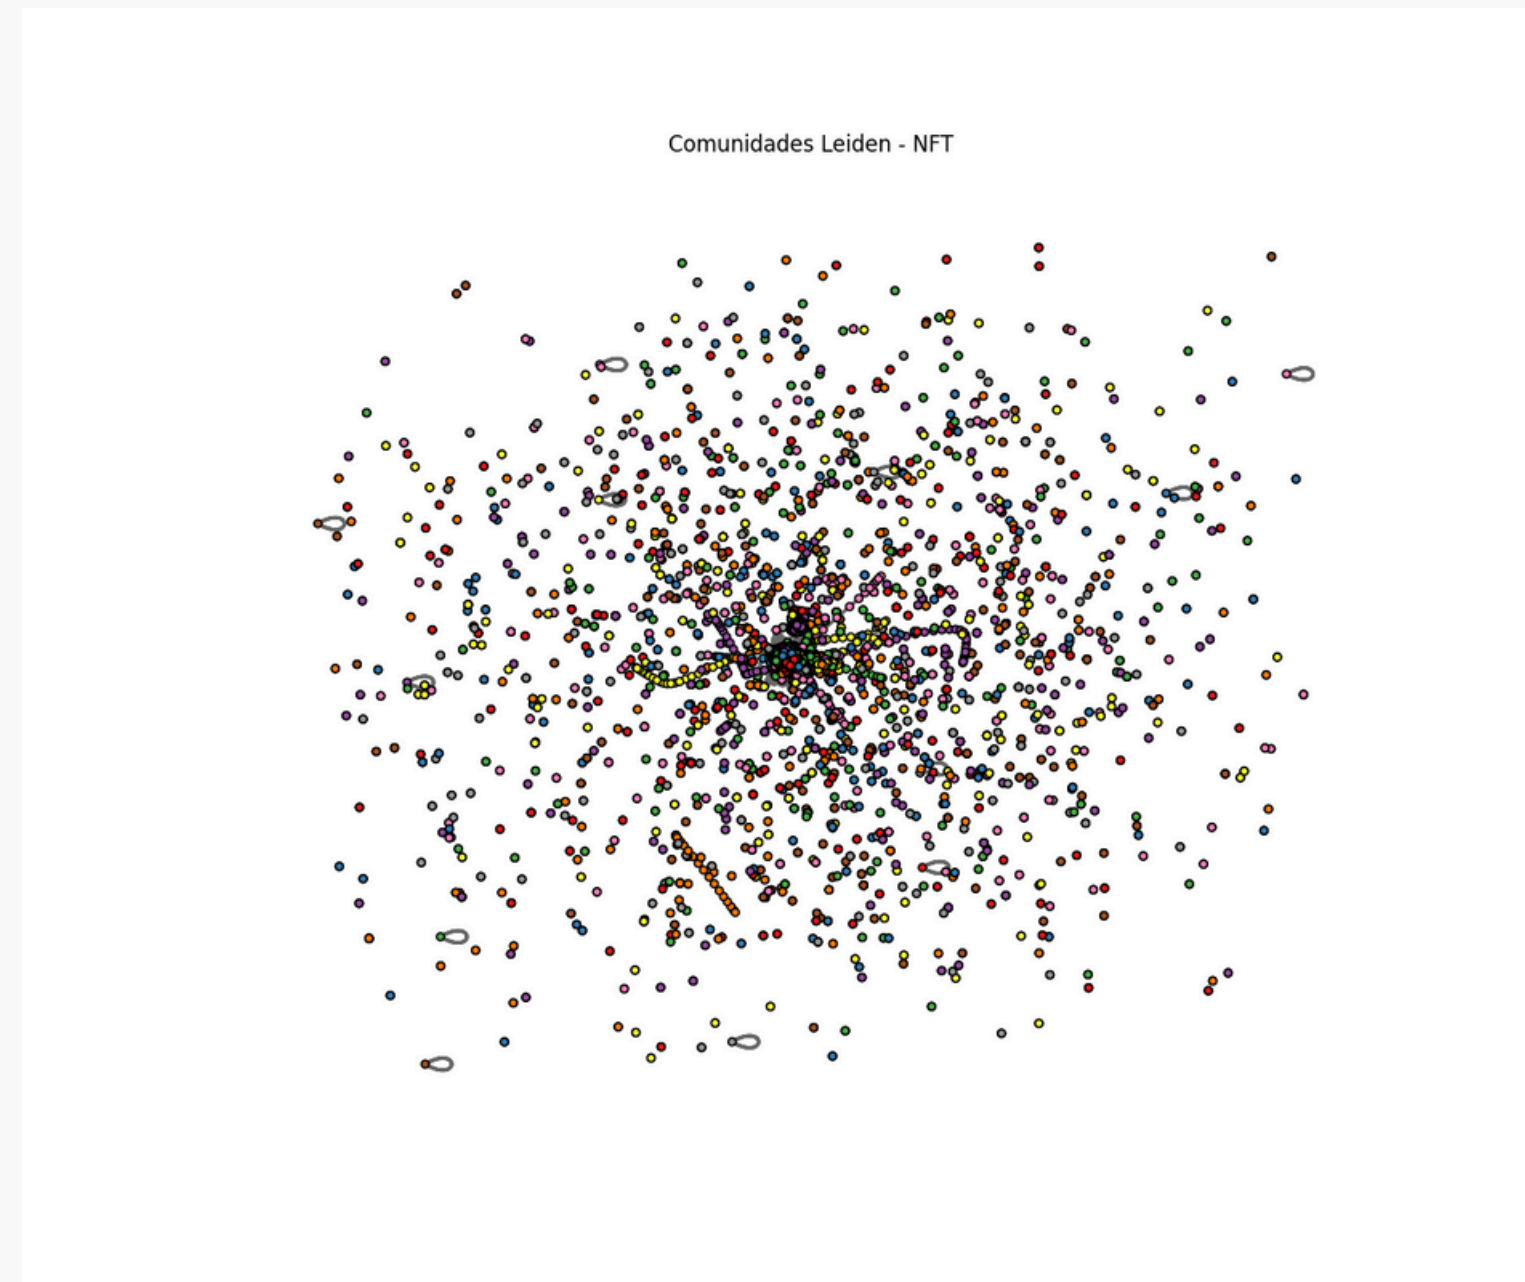
- Número de comunidades: 1601



Transações de NFT

Leiden


- Número de comunidades: 1602



Transações de NFT

Leiden (zoom)

- Número de comunidades: 1602



Conclusão

- Os três algoritmos oferecem boas abordagens para detectar comunidades.
- Leiden e Louvain são melhores para grandes redes e modularidade.
- Edge Betweenness é mais ‘interpretável’, mas computacionalmente custoso.

Referências

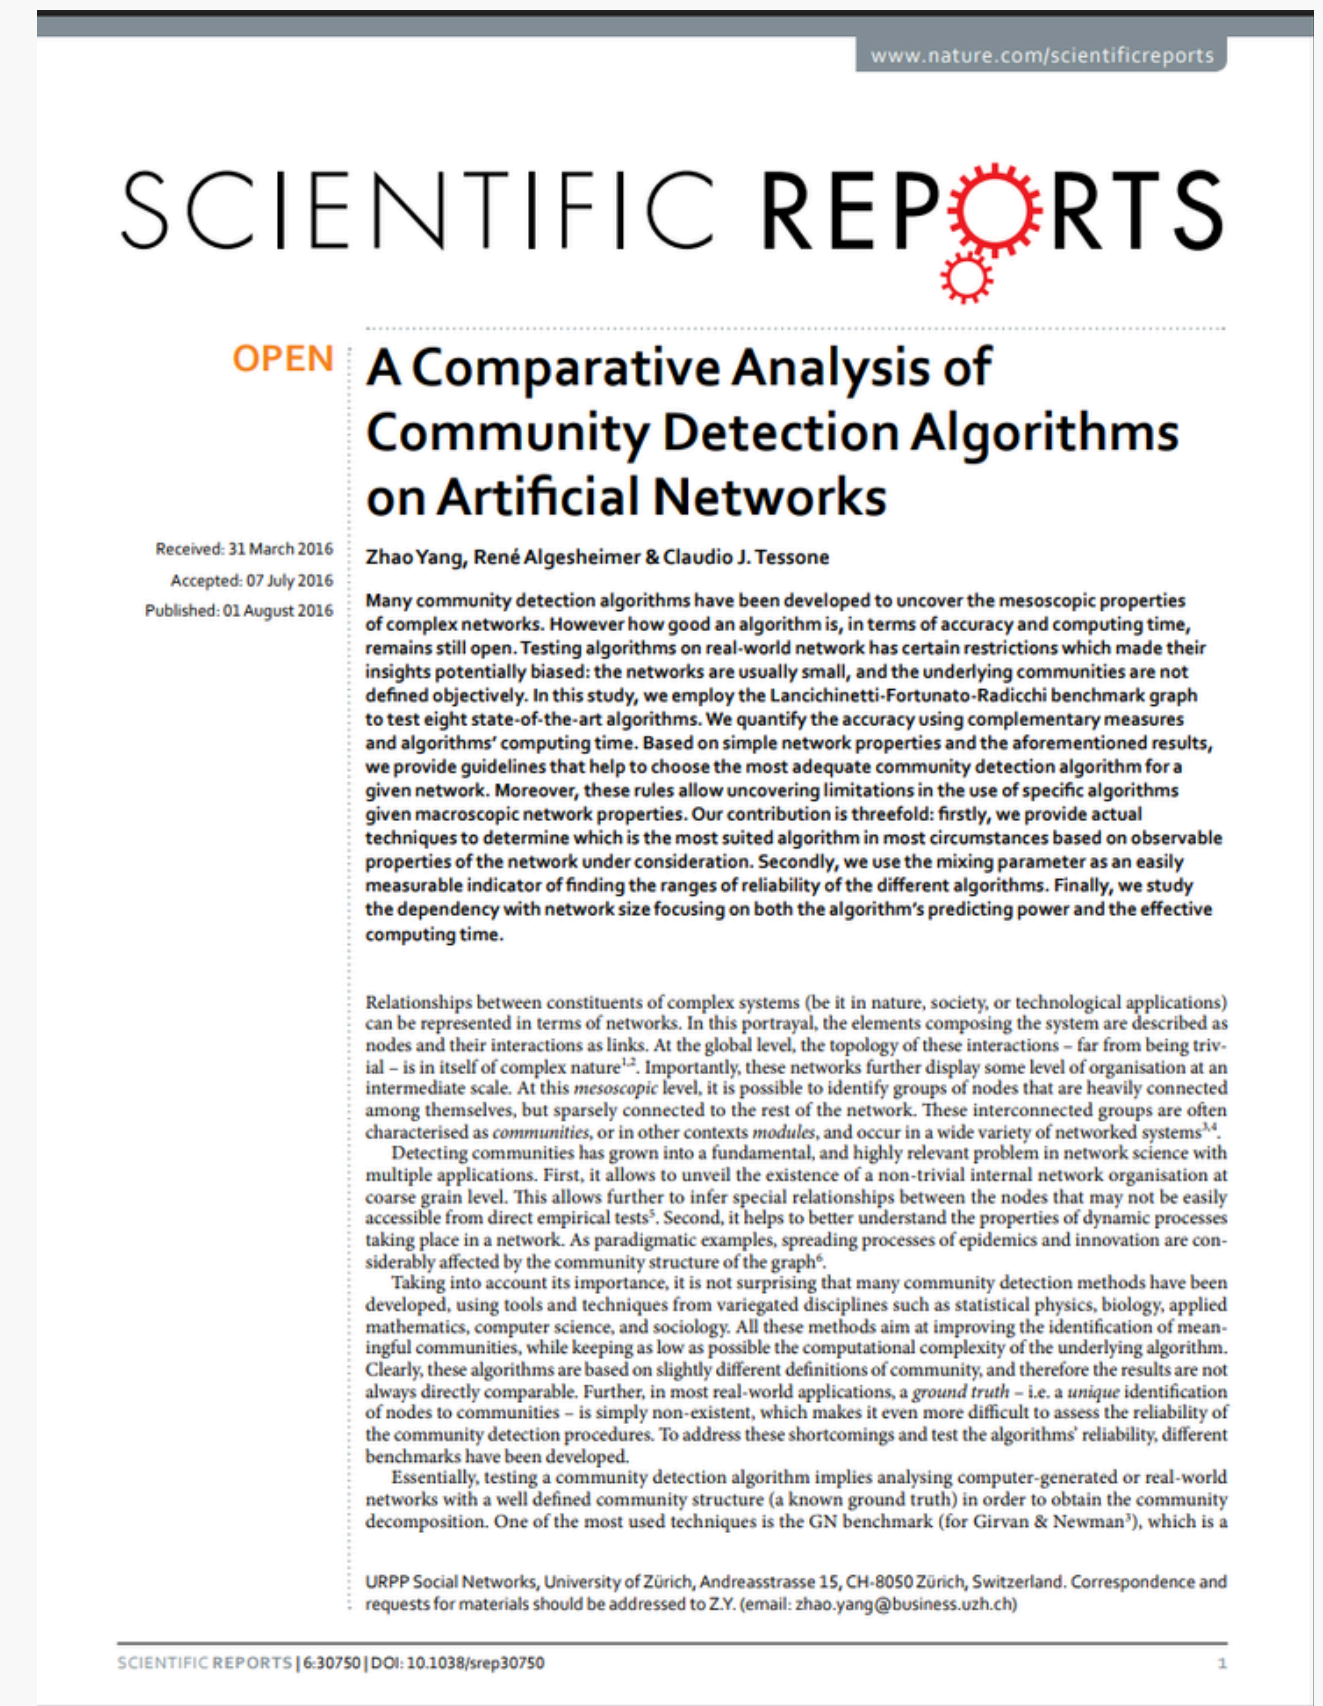

Nome do artigo:

A Comparative Analysis of Community Detection Algorithms on Artificial Networks

Fonte:

<https://www.nature.com/srep>

[Link para o artigo](#)



.....



Obrigado



.....